

O USO DE INTELIGÊNCIA ARTIFICIAL PARA O TREINAMENTO DE HUMANOIDES

SANTANA, Marcos Daniel¹

RESUMO

A robótica humanoide, um campo em rápida evolução, busca desenvolver robôs capazes de interagir com o ambiente de forma similar aos humanos. O treinamento desses humanoides é um desafio complexo, que tem sido revolucionado pela inteligência artificial (IA). Este trabalho de revisão bibliográfica analisa o estado da arte no uso da IA para o treinamento de robôs humanoides, explorando as principais técnicas como o aprendizado por reforço (Reinforcement Learning - RL), o aprendizado por imitação (Imitation Learning) e a integração de grandes modelos de linguagem (Large Language Models - LLMs). Discute-se a importância da transferência de aprendizado do ambiente simulado para o real (sim-to-real transfer) e as estratégias empregadas para mitigar a “lacuna da realidade” (reality gap). A pesquisa foi realizada em bases de dados científicas como Scopus, Web of Science, Google Scholar, IEEE Xplore, SpringerLink, ScienceDirect, ArXiv e Frontiers in Robotics and AI, focando em publicações dos últimos cinco anos (2020-2025). Os resultados indicam que a IA tem impulsionado significativamente a capacidade dos humanoides de adquirir habilidades complexas e adaptar-se a novas situações, com a integração de LLMs abrindo novas fronteiras para a compreensão de linguagem natural e raciocínio. Apesar dos avanços, desafios como a robustez em ambientes não estruturados e a generalização de habilidades persistem, exigindo pesquisa contínua e colaboração interdisciplinar para o desenvolvimento de humanoides mais autônomos, seguros e versáteis.

Palavras-Chave: Robótica Humanoide; Inteligência Artificial; Reinforcement Learning; Sim-to-Real; Large Language Models, Imitation Learning.

¹ Graduado em Engenharia Elétrica pela Faculdade Positivo, e Pós-Graduado em Robótica e Inteligência Artificial pela Faculdade Líbano.

1 INTRODUÇÃO

A robótica humanoide representa um dos campos mais desafiadores e promissores da engenharia e da inteligência artificial (IA). A capacidade de construir robôs que se assemelham e interagem com o ambiente de forma similar aos seres humanos abre portas para uma vasta gama de aplicações, desde assistência em tarefas domésticas e industriais até exploração de ambientes perigosos e interação social. No entanto, o desenvolvimento de humanoides autônomos e eficientes exige que eles sejam capazes de aprender e adaptar-se a novas situações, uma tarefa complexa que tem sido significativamente impulsionada pelos avanços na inteligência artificial, especialmente no que tange ao treinamento [1, 2].

O treinamento de robôs humanoides é um processo intrincado, que envolve a aquisição de habilidades motoras, percepção do ambiente, tomada de decisão e interação com humanos. Tradicionalmente, a programação manual de cada movimento e comportamento era um processo demorado e inflexível. A introdução de técnicas de IA, como o aprendizado por reforço (Reinforcement Learning - RL), o aprendizado por imitação (Imitation Learning) e o uso de modelos de linguagem grandes (Large Language Models - LLMs), tem revolucionado essa abordagem, permitindo que os robôs aprendam de forma mais autônoma e eficiente [3, 4].

A evolução da robótica humanoide pode ser dividida em três fases distintas. A primeira fase, caracterizada pela programação manual e controle baseado em regras, limitava os robôs a movimentos pré-definidos e ambientes estruturados. A segunda fase introduziu técnicas de aprendizado de máquina básicas, permitindo alguma adaptabilidade, mas ainda com limitações significativas na generalização. A terceira fase, que vivenciamos atualmente, é marcada pela integração de técnicas avançadas de IA, incluindo deep learning, aprendizado por reforço e modelos fundacionais, que permitem aos humanoides aprenderem comportamentos complexos e adaptar-se a ambientes dinâmicos [5, 6].

Este trabalho de revisão bibliográfica tem como objetivo analisar o estado da arte no uso da inteligência artificial para o treinamento de robôs humanoides. Serão exploradas as principais técnicas de IA empregadas, os desafios enfrentados na transferência de habilidades do ambiente simulado para o real (sim-to-real transfer), e as perspectivas futuras para o desenvolvimento de humanoides mais autônomos e adaptáveis. A relevância deste estudo reside na crescente demanda por robôs capazes de operar em ambientes não estruturados e na necessidade de otimizar os

processos de treinamento para acelerar sua integração em diversas áreas da sociedade.

A questão central que norteia esta revisão é: como as técnicas de inteligência artificial têm transformado o treinamento de robôs humanoides e quais são os principais desafios e oportunidades para o futuro? Para responder a essa pergunta, este trabalho examina criticamente a literatura recente, identificando tendências, lacunas e direções promissoras para pesquisas futuras.

2 METODOLOGIA

Este trabalho consiste em uma revisão bibliográfica de caráter qualitativo, com o objetivo de analisar o uso da inteligência artificial no treinamento de robôs humanoides. A abordagem metodológica seguiu um processo sistemático de coleta, seleção e análise de dados, garantindo a abrangência e a relevância das fontes consultadas.

A coleta de dados foi realizada em bases de dados científicas renomadas, abrangendo as áreas de robótica, inteligência artificial e aprendizado de máquina. As bases de dados consultadas incluem: Scopus, Web of Science, Google Scholar, IEEE Xplore, SpringerLink, ScienceDirect, ArXiv e Frontiers in Robotics and AI. A escolha dessas bases visa cobrir uma ampla gama de publicações de alto impacto e relevância acadêmica no campo da robótica e IA.

Para a seleção dos artigos, foram utilizados termos de busca abrangentes e específicos, combinando palavras-chave relacionadas à inteligência artificial e ao treinamento de humanoides. Os termos de busca empregados foram: “inteligência artificial treinamento humanoides”, “artificial intelligence humanoid training”, “reinforcement learning humanoid robot training”, “simulated training humanoid AI”, “AI control humanoid robot learning”, “humanoid robot skill acquisition AI”, entre outros. A pesquisa foi focada em publicações preferencialmente dos últimos cinco anos (2020-2025), visando capturar os avanços mais recentes na área e garantir a atualidade da revisão.

Os critérios de inclusão para a seleção dos artigos foram:

- Publicações em periódicos científicos revisados por pares.
- Anais de conferências de relevância na área de robótica e IA.
- Preprints de repositórios como o ArXiv que apresentassem resultados de pesquisa robustos e que fossem amplamente reconhecidos pela comunidade científica.

Foram aplicados os seguintes critérios de exclusão, a fim de refinar a seleção e garantir a qualidade e o foco da revisão:

- Publicações que focam apenas em plataformas muito específicas sem generalização (ex.: protótipos únicos sem validade além do caso de estudo), pois o objetivo é analisar abordagens que possam ser aplicadas a uma variedade de humanoides.

- Palestras, white papers sem avaliação acadêmica robusta, que não passaram por um processo de revisão por pares, garantindo a credibilidade das fontes.

Após a coleta inicial, os artigos foram submetidos a uma triagem baseada na leitura de títulos e resumos. Em seguida, os textos completos dos artigos selecionados foram lidos para verificar sua relevância e adequação aos objetivos da revisão. A análise dos materiais buscou identificar as principais técnicas de IA empregadas no treinamento de humanoides, os desafios e soluções propostas para a transferência de aprendizado do ambiente simulado para o real (sim-to-real transfer), e as tendências futuras da pesquisa neste campo. A síntese das informações foi realizada de forma crítica, comparando metodologias, resultados e limitações dos diferentes estudos, e buscando identificar lacunas no conhecimento existente.

3 DISCUSSÃO

O treinamento de robôs humanoides com inteligência artificial (IA) tem avançado significativamente nos últimos anos, impulsionado principalmente pelo desenvolvimento de algoritmos de aprendizado de máquina e pela crescente capacidade computacional. Esta seção discute as principais abordagens e desafios no uso da IA para o treinamento de humanoides, com base na literatura recente, oferecendo uma análise crítica das metodologias e resultados.

3.3 Aprendizado por Reforço (Reinforcement Learning - RL) no Treinamento de Humanoides

O Aprendizado por Reforço (RL) emergiu como uma das abordagens mais eficazes para o treinamento de robôs humanoides, permitindo que eles aprendam habilidades complexas através de tentativa e erro, otimizando suas ações com base em recompensas e punições. No contexto de humanoides, o RL é particularmente valioso porque permite que o robô descubra comportamentos ótimos em ambientes dinâmicos e complexos, sem a necessidade de programação explícita para cada cenário [7].

Artigos como o de Animoni Nagaraju et al. (2024) [1] demonstram a aplicação do Deep Reinforcement Learning (Deep RL) para ensinar habilidades dinâmicas a robôs humanoides de baixo custo, como andar, chutar e se recuperar de quedas em um cenário de jogo de futebol. A pesquisa destaca a capacidade do Deep RL de gerar comportamentos robustos e dinâmicos, mesmo com um número limitado de recompensas, e a eficiência na transferência do treinamento simulado para robôs reais. Criticamente, a capacidade de um robô de se recuperar rapidamente de uma queda, por exemplo, é um comportamento emergente que seria extremamente difícil de programar manualmente, mas que o RL pode otimizar através de milhões de iterações em simulação.

Outros trabalhos também enfatizam o papel do RL na locomoção bípede. Kim et al. (2024) [2] investigam técnicas de transferência sim-to-real para RL em locomoção bípede de humanoides, abordando a “lacuna da realidade” (reality gap) que surge ao transferir políticas aprendidas em simulação para o mundo físico. Eles avaliam sistematicamente técnicas como randomização de dinâmicas, uso de histórico de estados e modelagem de ruído para melhorar a robustez das políticas de RL, fornecendo insights cruciais para o avanço de robôs humanoides treinados por

RL em aplicações reais. A principal limitação aqui é a dificuldade de modelar com precisão todas as nuances do mundo real em um ambiente simulado, o que pode levar a um desempenho subótimo quando a política é transferida para o hardware físico.

A pesquisa do MIT (2025) [3] e da Science Robotics (2024) [4] reforça a ideia de que o RL, especialmente quando combinado com simulações avançadas, pode permitir que robôs aprendam habilidades complexas com surpreendente precisão e de forma mais rápida. A capacidade de treinar robôs em ambientes simulados, onde a coleta de dados é mais segura e eficiente, e depois transferir essas habilidades para o mundo real, é um pilar fundamental para o avanço do treinamento de humanoides. No entanto, a escalabilidade do treinamento em simulação para tarefas mais complexas e a garantia de que o comportamento aprendido seja seguro e previsível no mundo real ainda são desafios abertos.

3.3 Transferência Sim-to-Real e Ambientes de Simulação

A transferência de habilidades aprendidas em simulação para o mundo real (sim-to-real transfer) é um dos maiores desafios no treinamento de robôs humanoides. As diferenças entre os modelos físicos e as simulações, como atrito, rigidez das juntas e atrasos de comunicação, podem levar a uma degradação significativa do desempenho do robô no ambiente físico. Para mitigar essa lacuna, diversas estratégias têm sido exploradas:

- **Randomização de Domínio (Domain Randomization):** Esta técnica envolve a variação aleatória de parâmetros físicos e ambientais na simulação durante o treinamento. Ao expor o robô a uma ampla gama de condições, a política de controle torna-se mais robusta e generalizável para o mundo real. O trabalho de Kim et al. (2024) [2] exemplifica o uso dessa técnica, mostrando como a variação de parâmetros como massa, atrito e atrasos de sensores pode levar a políticas mais adaptáveis. A crítica a essa abordagem é que a randomização excessiva pode tornar o problema de aprendizado intratável, enquanto a randomização insuficiente pode não cobrir todas as variações do mundo real.
- **Modelagem de Ruído e Perturbações:** A inclusão de ruído e perturbações realistas na simulação ajuda a preparar o robô para as incertezas do ambiente físico. Isso inclui modelar ruídos nos sensores, atrasos de atuação e forças externas inesperadas. Essa abordagem visa tornar o ambiente simulado mais próximo

da realidade, mas requer um conhecimento aprofundado das características do ruído e das perturbações do sistema físico.

- **Aprendizado a partir de Dados Humanos:** A captura de movimento (motion capture) de humanos tem sido utilizada para fornecer dados de treinamento para humanoides, permitindo que eles aprendam a imitar movimentos complexos. A Movella (2024) [5] destaca como a captura de movimento e a IA são usadas para treinar robôs humanoides a mimetizar movimentos humanos e realizar tarefas complexas. Além disso, o ArXiv (2024) [6] apresenta o Humanoid-X, um grande conjunto de dados de poses de robôs humanoides com descrições de movimento baseadas em texto, coletado a partir de vídeos humanos, visando o aprendizado universal de poses. Embora promissora, a imitação direta pode não ser otimizada para a dinâmica específica do robô, e a generalização para novas tarefas pode ser limitada.

O uso de ambientes de simulação avançados, como o Omniverse da NVIDIA, tem sido crucial para acelerar o processo de treinamento. Esses ambientes permitem a criação de gêmeos digitais (digital twins) de robôs e cenários, possibilitando o treinamento em larga escala e a validação de políticas de controle antes da implantação no hardware físico. A NVIDIA (2024) [7] e o MIT (2025) [3] têm demonstrado como novas ferramentas de IA e simulação podem acelerar o desenvolvimento de robôs habilitados para IA, incluindo humanoides. A principal vantagem é a segurança e a velocidade do treinamento em simulação, mas a precisão do modelo de simulação continua sendo um fator crítico.

3.3 O Papel dos Grandes Modelos de Linguagem (LLMs) e Modelos Fundacionais

Recentemente, a integração de Grandes Modelos de Linguagem (LLMs) e outros modelos fundacionais tem aberto novas fronteiras para o treinamento de humanoides. Esses modelos permitem que os robôs compreendam e respondam a instruções em linguagem natural, além de raciocinar sobre tarefas complexas e gerar planos de ação. A revista Science (2025) [8] discute como o aprendizado de comportamentos complexos por robôs humanoides pode ser alcançado com interações naturais auxiliadas por LLMs. Isso representa um avanço significativo em relação aos sistemas de controle tradicionais, que exigiam programação explícita para cada tarefa.

Projetos como o Trinity (ArXiv, 2025) [9] e o GR00T N1 (ArXiv, 2025) [10] exemplificam essa tendência. O Trinity é um sistema de IA modular para robôs humanoides que integra RL, LLMs e Modelos de Visão-Linguagem (VLMs), permitindo que o robô processe informações multimodais e execute tarefas complexas. O GR00T N1, por sua vez, é um modelo fundacional aberto para robôs humanoides, com uma arquitetura de sistema dual (Visão-Linguagem-Ação), que visa criar robôs generalistas capazes de aprender e se adaptar a uma ampla gama de tarefas. A promessa desses modelos é a capacidade de generalizar para tarefas não vistas e de aprender com menos dados, mas a interpretabilidade e a robustez em cenários do mundo real ainda são áreas de pesquisa ativa.

Esses avanços sugerem uma mudança de paradigma, onde os robôs não apenas executam tarefas pré-programadas, mas também compreendem o contexto, aprendem com a experiência e interagem de forma mais intuitiva com os humanos. A capacidade de um humanoide de aprender a partir de demonstrações humanas e de dados visuais, como destacado pelo MIT (2024) [11] e pela ScienceDaily (2025) [12], é um passo crucial para a criação de robôs mais autônomos e versáteis. No entanto, a dependência de grandes volumes de dados para o treinamento desses modelos e o custo computacional associado são desafios a serem superados.

3.4 Desafios e Perspectivas Futuras

Apesar dos avanços notáveis, o treinamento de humanoides com IA ainda enfrenta desafios significativos. A robustez e a segurança dos robôs em ambientes não estruturados, a capacidade de generalizar habilidades para novas situações e a superação da lacuna da realidade continuam sendo áreas ativas de pesquisa. Além disso, questões éticas e sociais relacionadas à autonomia e à interação humano-robô são cada vez mais relevantes.

As perspectivas futuras incluem o desenvolvimento de algoritmos de RL mais eficientes em termos de dados, aprimoramento das técnicas de transferência sim-to-real, e a integração de modelos de IA cada vez mais sofisticados para permitir que os humanoides aprendam e se adaptem de forma contínua. A colaboração entre pesquisadores de IA, robótica e áreas como neurociência e psicologia será fundamental para impulsionar a próxima geração de robôs humanoides, capazes de interagir de forma inteligente e segura com o mundo ao seu redor. A criação de

benchmarks padronizados e a disponibilidade de plataformas de hardware e software abertas também serão cruciais para acelerar o progresso na área.

4 CONSIDERAÇÕES FINAIS

O presente trabalho de revisão bibliográfica explorou o panorama atual do uso da inteligência artificial no treinamento de robôs humanoides, destacando os avanços e desafios nesse campo em rápida evolução. Ficou evidente que a IA, em particular o aprendizado por reforço (RL), o aprendizado por imitação e a integração de grandes modelos de linguagem (LLMs), tem sido fundamental para capacitar humanoides a adquirir habilidades complexas e a interagir de forma mais autônoma com o ambiente.

A capacidade de treinar robôs em ambientes simulados e transferir essas políticas para o mundo real, embora ainda apresente a “lacuna da realidade”, tem sido aprimorada por técnicas como a randomização de domínio e a modelagem de ruído. A crescente sofisticação dos ambientes de simulação e a utilização de dados de movimento humano têm contribuído significativamente para a robustez e a naturalidade dos movimentos dos humanoides.

A emergência de modelos fundacionais e a integração de LLMs representam um marco importante, permitindo que os robôs não apenas executem tarefas, mas também compreendam instruções em linguagem natural, raciocinem e se adaptem a novas situações de forma mais flexível. Isso abre caminho para humanoides mais versáteis e capazes de atuar em uma gama mais ampla de aplicações, desde a indústria até o cuidado pessoal.

Contudo, desafios persistem, especialmente no que tange à robustez em ambientes não estruturados, à generalização de habilidades para novas situações e à superação completa da lacuna da realidade. A pesquisa futura deverá focar em algoritmos de aprendizado mais eficientes em termos de dados, em métodos aprimorados de transferência sim-to-real e na exploração de arquiteturas de IA que permitam um aprendizado contínuo e adaptativo. A colaboração interdisciplinar será crucial para o desenvolvimento de humanoides que não apenas sejam tecnologicamente avançados, mas também socialmente aceitáveis e benéficos para a humanidade.

Para sintetizar as principais técnicas de IA discutidas e suas aplicações no treinamento de humanoides, a Tabela 1 apresenta um resumo comparativo:

Tabela 1: Comparativo de Técnicas de IA no Treinamento de Humanoides

| Técnica de IA | Descrição | Aplicações no Treinamento de Humanoides | Vantagens | Desafios | Referências Chave |
|--|--|--|---|--|--------------------|
| Aprendizado por Reforço (RL) | Robô aprende por tentativa e erro, otimizando ações com base em recompensas. | Locomoção bípede, recuperação de quedas, manipulação de objetos, comportamentos dinâmicos. | Permite aprendizado autônomo de habilidades complexas; adaptabilidade a ambientes dinâmicos. | Requer muitas interações; “lacuna da realidade” na transferência sim-to-real; segurança. | [1], [2], [3], [4] |
| Aprendizado por Imitação (IL) | Robô aprende observando demonstrações humanas ou de outros robôs. | Reprodução de movimentos humanos, tarefas de manipulação delicadas, interação social. | Aprendizado rápido a partir de exemplos; comportamentos mais naturais. | Dificuldade em generalizar para novas situações; necessidade de dados de alta qualidade; otimização para a dinâmica do robô. | [5], [6] |
| Grandes Modelos de Linguagem (LLMs) | Modelos de IA que processam e geram linguagem natural. | Compreensão de instruções em linguagem natural; raciocínio sobre tarefas; geração de planos de ação. | Interação mais intuitiva; capacidade de raciocínio de alto nível; aprendizado de tarefas complexas. | Dependência de grandes volumes de dados; custo computacional; interpretabilidade e robustez em cenários do mundo real. | [8], [9], [10] |
| Modelos Fundacionais (VLMs) | Modelos multimodais que integram visão, linguagem e ação. | Percepção multimodal; aprendizado generalista; adaptação a diversas tarefas. | Capacidade de processar diferentes tipos de dados; aprendizado mais abrangente e adaptável. | Complexidade de integração; desafios na generalização para tarefas não vistas; custo computacional. | [9], [10] |

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] NAGARAJU, Animoni et al. **Deep Reinforcement Learning for Low-Cost Humanoid Robot Soccer Players**: Dynamic Skills and Efficient Transfer. In: 2023 Seventh International Conference on Computing and Communications Technologies (ICCT). IEEE, 2024. Disponível em: <<https://ieeexplore.ieee.org/document/10537661/>>. Acesso em: 22 jul. 2025.
- [2] KIM, Donghyeon et al. **Bridging the Reality Gap**: Analyzing Sim-to-Real Transfer Techniques for Reinforcement Learning in Humanoid Bipedal Locomotion. IEEE Robotics & Automation Magazine, v. 32, n. 1, p. 49-58, 2024. Disponível em: <<https://ieeexplore.ieee.org/document/10795482/>>. Acesso em: 22 jul. 2025.
- [3] MIT News. **A faster, better way to train general-purpose robots**. 28 out. 2024. Disponível em: <<https://news.mit.edu/2024/training-general-purpose-robots-faster-better-1028>>. Acesso em: 22 jul. 2025.
- [4] Science Robotics. **Real-world humanoid locomotion with reinforcement learning**. 17 abr. 2024. Disponível em: <<https://www.science.org/doi/10.1126/scirobotics.adi9579>>. Acesso em: 22 jul. 2025.
- [5] MOVELLA. Motion capture: **Teaching humanoid robots how to move like humans**. 24 set. 2024. Disponível em: <<https://www.movella.com/resources/cases/humanoid-robots-learning-human-movement-using-xsens-motion-capture>>. Acesso em: 22 jul. 2025.
- [6] ARXIV. **Learning from Massive Human Videos for Universal Humanoid Pose**. 18 dez. 2024. Disponível em: <<https://arxiv.org/abs/2412.14172>>. Acesso em: 22 jul. 2025.
- [7] NVIDIA. NVIDIA **Advances Robot Learning, Humanoid Development With AI and Simulation Tools**. 6 nov. 2024. Disponível em: <<https://blogs.nvidia.com/blog/robot-learning-humanoid-development/>>. Acesso em: 22 jul. 2025.
- [8] Science Robotics. **Humanoid robot learning of complex behaviors with LLMs**. 22 jan. 2025. Disponível em: <<https://www.science.org/doi/10.1126/scirobotics.adv4627>>. Acesso em: 22 jul. 2025.
- [9] ARXIV. **Trinity**: A Modular Humanoid Robot AI System. 11 mar. 2025. Disponível em: <<https://arxiv.org/html/2503.08338v1>>. Acesso em: 22 jul. 2025.
- [10] ARXIV. **GR00T N1**: An Open Foundation Model for Generalist Humanoid Robots. 18 mar. 2025. Disponível em: <<https://arxiv.org/abs/2503.14734>>. Acesso em: 22 jul. 2025.
- [11] SCIENCE DAILY. **Robots learning without us?**: New study cuts humans from early testing. 19 maio 2025. Disponível em: <<https://www.sciencedaily.com/releases/2025/05/250519132026.htm>>. Acesso em: 22 jul. 2025.

[12] National Institute of Biomedical imaging and Bioengineering. **AI-powered simulation training improves human performance in robotic exoskeletons**. 13 jun. 2024. Disponível em: <<https://www.nibib.nih.gov/news-events/newsroom/ai-powered-simulation-training-improves-human-performance-robotic-exoskeletons>>. Acesso em: 22 jul. 2025.